

Analisis Pengaruh Kemiskinan dan Rata Lama Sekolah Terhadap Pembangunan Wilayah di Indonesia

Teknologi Rekayasa Perangkat Lunak
2025/2026

KELOMPOK 9

1. Aulia Rezki Rahman - J0403251009
2. Ibra Arifa Istara - J0403251029
3. Muhammad Raihan Ramadhan - J0403251038
4. Ihsan Hamizan - J0403251051
5. Ivan Farel Aditya - J0403251087
6. Raffan Fatih Zulfan - J0403251091

BAB I PENDAHULUAN

1.1 Latar Belakang

Pembangunan wilayah yang komprehensif tidak hanya diukur dari pertumbuhan infrastruktur fisik, tetapi juga dari peningkatan taraf hidup dan kesejahteraan masyarakatnya. Salah satu indikator utama yang masih menjadi tantangan dalam pembangunan di berbagai wilayah di Indonesia adalah tingkat kemiskinan (Kuncoro 2010). Kemiskinan merupakan fenomena multidimensional yang dipengaruhi oleh berbagai faktor sosial dan ekonomi. Dalam pendekatan makroekonomi, kualitas sumber daya manusia dan ketersediaan lapangan pekerjaan dianggap sebagai dua pilar krusial yang dapat mengentaskan masyarakat dari garis kemiskinan.

Teori human capital atau modal manusia menegaskan bahwa pendidikan formal merupakan investasi jangka panjang yang berbanding lurus dengan peningkatan produktivitas dan kapabilitas ekonomi seseorang (Toldaro dan Smith 2015). Hal ini direpresentasikan oleh indikator rata-rata lama sekolah. Logika statistiknya, semakin tinggi durasi pendidikan yang diselesaikan oleh penduduk di suatu wilayah, semakin besar peluang mereka untuk diserap oleh pasar kerja yang layak, sehingga tingkat kemiskinan dapat ditekan. Sebaliknya, ketidakmampuan pasar kerja dalam menyerap angkatan kerja akan memicu tingginya angka pengangguran terbuka. Tingkat pengangguran yang tinggi secara langsung memutus aliran pendapatan individu, yang pada akhirnya bermuara pada peningkatan persentase kemiskinan wilayah (Sukirno, 2011).

Dalam pengolahan data riil terkait indikator-indikator tersebut, analisis sering dihadapkan pada masalah kualitas data, seperti adanya data yang hilang (missing value) atau nilai anomali yang ekstrem (outlier). Oleh karena itu, proyek ini disusun untuk melakukan analisis statistika secara komprehensif menggunakan bahasa pemrograman R. Evaluasi difokuskan pada penerapan statistika deskriptif, penanganan ketidaksempurnaan

data, hingga pembuktian statistik mengenai korelasi antara rata-rata lama sekolah dan tingkat pengangguran terhadap persentase kemiskinan di berbagai wilayah.

1.2 Tujuan

Tujuan dari analisis data pembangunan wilayah ini adalah sebagai berikut:

1. Memahami struktur dan karakteristik dataset.
2. Melakukan eksplorasi data menggunakan R.
3. Mengidentifikasi missing value dan outlier.
4. Melakukan statistika deskriptif.
5. Membuat visualisasi data yang informatif.
6. Menggunakan konsep probabilitas dan distribusi data.
7. Melakukan analisis hubungan antar variabel.
8. Menarik kesimpulan berbasis data.
9. Menyusun laporan ilmiah sederhana.
10. Mengkomunikasikan hasil analisis secara sistematis.

1.3 Deskripsi Dataset

Dataset yang digunakan dalam analisis ini adalah `pembangunan_wilayah_missing_outlier.csv`. Untuk menjawab tujuan pengamatan, analisis difokuskan pada dua variabel utama pengukur kualitas sumber daya manusia dan tenaga kerja, beserta variabel identitas wilayahnya. Berikut adalah rincian variabel yang digunakan:

1. wilayah (Character): Nama kabupaten/kota yang menjadi objek pengamatan.
2. provinsi (Character): Nama provinsi tempat wilayah berada.
3. tahun (Integer): Tahun pengamatan data pembangunan wilayah.
4. pdrb_perkapita (Numeric): Produk Domestik Regional Bruto (PDRB) per kapita yang menggambarkan tingkat aktivitas ekonomi dan pendapatan rata-rata masyarakat suatu wilayah.
5. kemiskinan (Numeric): Persentase penduduk miskin pada suatu wilayah.
6. pengangguran (Numeric): Persentase tingkat pengangguran pada suatu wilayah.
7. ipm (Numeric): Indeks Pembangunan Manusia yang menggambarkan kualitas hidup masyarakat berdasarkan pendidikan, kesehatan, dan standar hidup.
8. harapan_hidup (Numeric): Rata-rata perkiraan umur yang dapat dicapai penduduk pada suatu wilayah.
9. rata_lama_sekolah (Numeric): Rata-rata jumlah tahun pendidikan formal yang telah ditempuh penduduk.
10. akses_internet (Numeric): Persentase masyarakat yang memiliki atau menggunakan akses internet.
11. jalan_baik (Numeric): Persentase kondisi jalan yang berada dalam kategori baik.
12. air_bersih (Numeric): Persentase masyarakat yang memiliki akses terhadap air bersih.
13. catatan_data (Character): Keterangan kondisi data, misalnya data normal, mengandung missing value, atau outlier.

Pada proyek analisis data pembangunan wilayah ini, kami memilih variabel kemiskinan dan rata_lama_sekolah sebagai fokus pembahasan. Variabel kemiskinan dan rata_lama_sekolah dipilih karena keduanya merupakan indikator penting dalam pembangunan wilayah. Variabel kemiskinan menggambarkan tingkat kesejahteraan masyarakat, sedangkan rata_lama_sekolah menggambarkan tingkat pendidikan penduduk.

Kedua variabel ini dipilih karena pendidikan dan kesejahteraan memiliki hubungan yang erat dalam pembangunan suatu wilayah. Tingkat pendidikan yang lebih baik dapat meningkatkan kualitas sumber daya manusia dan peluang kerja, yang pada akhirnya dapat berkontribusi terhadap penurunan tingkat kemiskinan. Oleh karena itu, analisis kedua variabel ini dapat memberikan gambaran mengenai kondisi pembangunan wilayah dari aspek pendidikan dan kesejahteraan masyarakat.

BAB II METODOLOGI

2.1 Tools

Dalam pengerjaan proyek ini, beberapa perangkat lunak dan platform yang digunakan antara lain:

1. R dan R Studio: Digunakan sebagai *environment* utama komputasi statistik. Modul yang dieksekusi mengandalkan *library* spesifik, yaitu:
 - **dplyr**: Untuk memanipulasi *dataframe* (*piping*, *filter*, *select*, *mutate*).
 - **ggplot2**: Untuk merender visualisasi grafis berlapis (*grammar of graphics*).
2. GitHub: Digunakan sebagai repositori kolaborasi untuk mengontrol versi (*version control*) kode R dan dokumen laporan.

2.2 Metode Analisis

Analisis data dalam laporan ini dilakukan melalui serangkaian tahapan komputasi statistik menggunakan bahasa pemrograman R. Berikut adalah tahapan metode analisis yang diterapkan:

1. Statistika Deskriptif Pada tahap ini, dilakukan ekstraksi parameter statistik dari variabel dependen (kemiskinan) dan variabel independen (rata-rata lama sekolah dan pengangguran). Pengukuran mencakup nilai pemusatan data (Rata-rata/ *Mean* dan Nilai Tengah/ *Median*) serta penyebaran data (Nilai Minimum, Maksimum, Kuartil 1, Kuartil 3, Standar Deviasi, dan Varians).
2. Pra-pemrosesan Data (*Data Pre-processing*) Dataset mentah sering kali memiliki ketidaksempurnaan, sehingga perlu dilakukan pembersihan data yang mencakup dua penanganan utama:
 - Penanganan *Missing Value*: Identifikasi data yang kosong (NA) dilakukan pada seluruh kolom. Penanganan dilakukan dengan metode imputasi median, di mana nilai yang hilang diisi dengan nilai tengah (median) dari masing-masing variabel menggunakan fungsi dari paket **dplyr**. Median dipilih karena sifatnya yang tangguh (*robust*) dan tidak mudah terpengaruh oleh nilai ekstrem.
 - Penanganan *Outlier*: Pendeteksian nilai ekstrem dilakukan menggunakan bantuan *Boxplot* dan metode *Interquartile Range* (IQR). Observasi yang berada di luar batas kewajaran—yaitu lebih kecil dari kuartil bawah dikurangi 1.5 IQR atau lebih besar dari kuartil atas ditambah 1.5 IQR—akan disaring (*filter*) agar tidak mengganggu keakuratan pemodelan selanjutnya.
3. Visualisasi Data Eksplorasi visual dilakukan menggunakan pustaka **ggplot2** untuk melihat pola dan distribusi data secara lebih intuitif. Visualisasi yang dibuat meliputi *Bar chart* (untuk membandingkan jumlah laporan antar tahun dan provinsi), *Boxplot* (untuk melihat penyebaran Indeks Pembangunan Manusia), serta *Scatter plot* (untuk melihat sebaran awal hubungan antar variabel).

4. Analisis Korelasi Untuk menguji hipotesis hubungan antar variabel, dilakukan uji korelasi Pearson. Uji ini bertujuan untuk mengetahui seberapa kuat dan ke arah mana (positif atau negatif) hubungan linier yang terjadi antara tingkat pendidikan (rata-rata lama sekolah) dengan tingkat kemiskinan, serta persentase pengangguran dengan kemiskinan. Hasil analisis numerik ini juga divisualisasikan dengan garis regresi pada *Scatter plot*.
5. Analisis Probabilitas dan Distribusi Data Tahap terakhir adalah melakukan uji kenormalan distribusi pada variabel yang dianalisis. Pengujian dilakukan melalui visualisasi grafis berlapis, yaitu dengan memetakan kurva densitas probabilitas di atas histogram, serta menggunakan *Quantile-Quantile Plot* (Q-Q Plot) untuk melihat apakah sebaran titik data sejajar dengan garis normal teoritis.

BAB III HASIL DAN PEMBAHASAN

3.1 Statistika Deskriptif

Analisis statistika deskriptif dilakukan terhadap seluruh variabel numerik dalam dataset, yaitu `pdrb_perkapita`, `kemiskinan`, `pengangguran`, `ipm`, `harapan_hidup`, `rata_lama_sekolah`, `akses_internet`, `jalan_baik`, dan `air_bersih`. Statistik yang dihitung meliputi mean, median, minimum, maksimum, kuartil, standar deviasi, dan varians.

Berdasarkan hasil analisis, variabel `pdrb_perkapita` memiliki nilai rata-rata (mean) tertinggi, yaitu sebesar 135.650.500. Hal ini menunjukkan bahwa nilai PDRB per kapita memiliki skala yang jauh lebih besar dibandingkan variabel numerik lainnya dalam dataset.

Dilihat dari ukuran penyebaran data, variabel `pdrb_perkapita` juga memiliki standar deviasi terbesar, yaitu sekitar 89.341.270, dengan varians sebesar $7,98 \times 10^{15}$. Nilai tersebut menunjukkan bahwa data PDRB per kapita memiliki variasi yang sangat besar antar wilayah yang diamati.

Selain itu, terdapat indikasi bahwa distribusi data `pdrb_perkapita` tidak sepenuhnya normal. Hal ini terlihat dari rentang data yang sangat lebar, yaitu dari 15.031.581 hingga 1.774.545.000, serta adanya perbedaan yang cukup besar antara nilai minimum dan maksimum. Kondisi tersebut mengindikasikan kemungkinan adanya nilai ekstrem (outlier) yang menyebabkan distribusi data menjadi tidak simetris.

```
# memahami dataset
data <- read.csv("../dataset/pembangunan_wilayah_missing_outlier.csv")
str(data)
```

```
## 'data.frame':    2500 obs. of  13 variables:
## $ wilayah      : chr  "Kabupaten/Kota_1" "Kabupaten/Kota_2" "Kabupaten/Kota_3" "Kabupaten/Kota_4" ...
## $ provinsi     : chr  "Jawa Barat" "Jawa Timur" "Kalimantan Timur" "DKI Jakarta" ...
## $ tahun        : int  2022 2022 2020 2022 2023 2020 2024 2023 2023 2020 ...
## $ pdrb_perkapita : num  3.84e+07 1.66e+08 2.68e+07 1.55e+08 1.99e+08 ...
## $ kemiskinan   : num  19.69 9.68 4.13 20.43 14.39 ...
## $ pengangguran : num  4.73 4.43 2.99 3.9 12.15 ...
## $ ipm          : num  80.2 55 78.7 73.3 72.9 ...
## $ harapan_hidup : num  75.8 67.8 60.4 69.5 75 ...
## $ rata_lama_sekolah: num  8.41 5.79 13.2 12.28 9.69 ...
## $ akses_internet : num  63.9 66.6 64.7 44.6 52.7 ...
## $ jalan_baik    : num  53.9 34.9 48.6 57.9 65.7 ...
## $ air_bersih    : num  43.1 58.9 90.3 86.2 90.8 ...
## $ catatan_data  : chr  "Normal" "Normal" "Normal" "Normal" ...
```

```
head(data)
```

```
##           wilayah           provinsi tahun pdrb_perkapita kemiskinan
## 1 Kabupaten/Kota_1 Jawa Barat 2022      38403994      19.69
## 2 Kabupaten/Kota_2 Jawa Timur 2022      165582092      9.68
## 3 Kabupaten/Kota_3 Kalimantan Timur 2020      26780948      4.13
## 4 Kabupaten/Kota_4 DKI Jakarta 2022      155034790      20.43
## 5 Kabupaten/Kota_5 Sulawesi Selatan 2023      198834591      14.39
## 6 Kabupaten/Kota_6 Jawa Timur 2020      145702606      17.14
##   pengangguran ipm harapan_hidup rata_lama_sekolah akses_internet jalan_baik
## 1      4.73 80.16      75.75      8.41      63.86      53.86
## 2      4.43 55.05      67.85      5.79      66.61      34.89
## 3      2.99 78.70      60.38     13.20      64.73      48.57
## 4      3.90 73.27      69.49     12.28      44.59      57.88
## 5     12.15 72.90      75.00      9.69      52.72      65.70
## 6      3.38 65.11      67.04      5.66      55.63      70.12
##   air_bersih catatan_data
## 1      43.11      Normal
## 2      58.93      Normal
## 3      90.27      Normal
## 4      86.16      Normal
## 5      90.84      Normal
## 6      60.17      Normal
```

```
dim(data)
```

```
## [1] 2500 13
```

```
summary(data)
```

```
##           wilayah           provinsi           tahun           pdrb_perkapita
## Length:2500      Length:2500      Min.   :2020      Min.   :1.503e+07
## Class :character  Class :character  1st Qu.:2021      1st Qu.:6.962e+07
## Mode  :character  Mode  :character  Median :2022      Median :1.373e+08
##                                     Mean   :2022      Mean   :1.357e+08
##                                     3rd Qu.:2023      3rd Qu.:1.939e+08
##                                     Max.   :2024      Max.   :1.775e+09
##                                     NA's    :25
##   kemiskinan   pengangguran           ipm           harapan_hidup
## Min.   : 2.01   Min.   : 1.010   Min.   :55.01   Min.   :60.01
## 1st Qu.: 7.86   1st Qu.: 4.350   1st Qu.:62.52   1st Qu.:64.66
## Median :13.72   Median : 8.230   Median :69.89   Median :69.30
## Mean   :13.72   Mean   : 8.046   Mean   :69.90   Mean   :69.13
## 3rd Qu.:19.39   3rd Qu.:11.520   3rd Qu.:77.16   3rd Qu.:73.58
## Max.   :67.53   Max.   :47.040   Max.   :84.99   Max.   :77.99
## NA's    :24     NA's    :25     NA's    :25
##   rata_lama_sekolah akses_internet   jalan_baik   air_bersih
## Min.   : 5.020   Min.   : 0.01   Min.   :30.01   Min.   :40.03
## 1st Qu.: 7.327   1st Qu.:38.91   1st Qu.:47.40   1st Qu.:54.32
## Median : 9.520   Median :58.09   Median :65.02   Median :69.68
## Mean   : 9.581   Mean   :58.79   Mean   :65.26   Mean   :69.76
## 3rd Qu.:11.912   3rd Qu.:78.67   3rd Qu.:83.24   3rd Qu.:85.18
```

```
## Max. :14.000 Max. :97.99 Max. :99.95 Max. :99.99
## NA's :25 NA's :25
## catatan_data
## Length:2500
## Class :character
## Mode :character
##
##
##
##
```

```
sapply(data, class)
```

```
## wilayah provinsi tahun pdrb_perkapita
## "character" "character" "integer" "numeric"
## kemiskinan pengangguran ipm harapan_hidup
## "numeric" "numeric" "numeric" "numeric"
## rata_lama_sekolah akses_internet jalan_baik air_bersih
## "numeric" "numeric" "numeric" "numeric"
## catatan_data
## "character"
```

```
options(scipen = 999)
```

```
numerik <- data[sapply(data, is.numeric)]
numerik <- numerik %>% select(-tahun)
```

```
statistik_deskriptif <- data.frame(
  Variabel = names(select(numerik, where(is.numeric))),
  Mean = sapply(select(numerik, where(is.numeric)), mean, na.rm = TRUE),
  Median = sapply(select(numerik, where(is.numeric)), median, na.rm = TRUE),
  Min = sapply(select(numerik, where(is.numeric)), min, na.rm = TRUE),
  Q1 = sapply(select(numerik, where(is.numeric)), quantile, probs = 0.25, na.rm = TRUE),
  Q2 = sapply(select(numerik, where(is.numeric)), quantile, probs = 0.50, na.rm = TRUE),
  Q3 = sapply(select(numerik, where(is.numeric)), quantile, probs = 0.75, na.rm = TRUE),
  Max = sapply(select(numerik, where(is.numeric)), max, na.rm = TRUE),
  SD = sapply(select(numerik, where(is.numeric)), sd, na.rm = TRUE),
  Varians = sapply(select(numerik, where(is.numeric)), var, na.rm = TRUE)
)
```

```
statistik_deskriptif
```

##	Variabel	Mean	Median	Min
##	pdrb_perkapita	135650462.480808	137310624.000	15031581.00
##	kemiskinan	13.721458	13.720	2.01
##	pengangguran	8.045733	8.230	1.01
##	ipm	69.899992	69.890	55.01
##	harapan_hidup	69.130152	69.295	60.01
##	rata_lama_sekolah	9.580684	9.520	5.02
##	akses_internet	58.789030	58.090	0.01
##	jalan_baik	65.258085	65.020	30.01
##	air_bersih	69.761528	69.680	40.03
##	Q1	Q2	Q3	Max

```
## pdrb_perkapita      69622210.0000 137310624.000 193899157.0000 1774545027.00
## kemiskinan          7.8600          13.720          19.3925          67.53
## pengangguran        4.3500          8.230          11.5200          47.04
## ipm                 62.5200         69.890          77.1600          84.99
## harapan_hidup       64.6575         69.295          73.5850          77.99
## rata_lama_sekolah    7.3275          9.520          11.9125          14.00
## akses_internet      38.9150         58.090          78.6700          97.99
## jalan_baik          47.3950         65.020          83.2400          99.95
## air_bersih          54.3175         69.680          85.1825          99.99
##                      SD                      Varians
## pdrb_perkapita      89341269.948222 7981862515961076.000000
## kemiskinan          6.894704          47.536939
## pengangguran        4.258576          18.135468
## ipm                 8.535062          72.847280
## harapan_hidup       5.171779          26.747295
## rata_lama_sekolah    2.627008          6.901173
## akses_internet      22.820297          520.765976
## jalan_baik          20.365689          414.761280
## air_bersih          17.499206          306.222196
```

3.2 Missing Value

Missing value adalah nilai yang dimaksudkan untuk didapatkan saat pengumpulan data, namun tidak berhasil didapatkan karena alasan tertentu. *Missing value* dapat muncul karena responden tidak menjawab semua pertanyaan di kuisioner, kesalahan pengukuran, kesalahan proses data entri, dan lain-lain (Kaiser 2014). Untuk mengatasi *missing value*, dibutuhkan metode penanganan *missing value*.

Salah satu metode penanganan *missing value* adalah *median imputation*. *Median imputation* adalah metode mengganti *missing value* dengan nilai median dari variabel yang bersangkutan pada dataset (Alam *et al.* 2023). Pada dataset yang kami teliti, terdapat *missing value* pada beberapa variabel yang akan ditangani. Kami mencari nilai median dari masing-masing variabel dan mengisi nilai median tersebut pada bagian yang hilang.

```
missing_value <- colSums(is.na(data))
missing_value
```

```
##          wilayah          provinsi          tahun      pdrb_perkapita
##             0             0             0             25
##      kemiskinan      pengangguran          ipm      harapan_hidup
##             24             25             25             0
## rata_lama_sekolah      akses_internet      jalan_baik      air_bersih
##             0             25             25             0
##      catatan_data
##             0
```



```
data <- data %>%
  mutate(across(where(is.numeric),
    ~ ifelse(is.na(.), median(., na.rm = TRUE), .)))
colSums(is.na(data))
```


```
##          wilayah          provinsi          tahun      pdrb_perkapita
```

```
##          0          0          0          0
##      kemiskinan      pengangguran          ipm      harapan_hidup
##          0          0          0          0
## rata_lama_sekolah      akses_internet      jalan_baik      air_bersih
##          0          0          0          0
##      catatan_data
##          0
```

3.3 Outlier

Outlier adalah nilai ekstrem yang secara tidak normal berada diluar pola distribusi keseluruhan suatu variabel (Kwak dan Kim 2017). Untuk menangani *outlier* tersebut, kami menggunakan metode *trimming*. *Trimming* adalah metode menghapus *outlier* dari dataset. Metode tersebut dipilih karena jumlah outlier tidak terlalu banyak, sehingga tidak akan terlalu memengaruhi dataset ketika *outlier* dipangkas.






Pada dataset yang kami teliti, terdapat total 15 *outlier* yang tersebar di beberapa variabel. Secara rinci, variabel `pdrb_perkapita` memiliki 5 *outlier*, variabel kemiskinan memiliki 5 *outlier*, dan variabel pengangguran memiliki 5 *outlier*. Semua data *outlier* tersebut dipangkas sehingga jumlah kolom pada dataset berkurang dari 2500 menjadi 2485.

```
# Metode trimming
iqr_pdrb <- IQR(data$pdrb_perkapita)
batas_bawah <- quantile(data$pdrb_perkapita, 0.25) - (1.5 * iqr_pdrb)
batas_atas <- quantile(data$pdrb_perkapita, 0.75) + (1.5 * iqr_pdrb)
data <- data %>%
  filter(pdrb_perkapita >= batas_bawah & pdrb_perkapita <= batas_atas)

iqr_kemiskinan <- IQR(data$kemiskinan)
batas_bawah <- quantile(data$kemiskinan, 0.25) - (1.5 * iqr_kemiskinan)
batas_atas <- quantile(data$kemiskinan, 0.75) + (1.5 * iqr_kemiskinan)
data <- data %>%
  filter(kemiskinan >= batas_bawah & kemiskinan <= batas_atas)


iqr_datapengangguran <- IQR(data$pengangguran)
batas_bawah <- quantile(data$pengangguran, 0.25) - (1.5 * iqr_datapengangguran)
batas_atas <- quantile(data$pengangguran, 0.75) + (1.5 * iqr_datapengangguran)
data <- data %>%
  filter(pengangguran >= batas_bawah & pengangguran <= batas_atas)
```

3.4 Visualisasi




Rangkuman Grafik :

Ke-10 provinsi memiliki jumlah laporan berkisar diatas 200, jumlah laporan terkecil berasal dari Provinsi Sulawesi Selatan dan jumlah laporan terbanyak berasal dari Provinsi Kalimantan Timur.




Rangkuman Grafik :

Dari tahun 2020 hingga 2024 jumlah laporan konsisten diatas 400-an dengan jumlah laporan tertinggi terjadi pada tahun 2020.




Rangkuman Grafik :

Semakin tinggi tingkat kemiskinan ternyata tidak terlalu mempengaruhi nilai pdrb_perkapita. artinya kemungkinan nilai korelasi antara variabel kemiskinan dengan variabel pdrb_perkapita tidak terlalu kuat.



Rangkuman Grafik :

Distribusi data tidak berbentuk distribusi normal. Dalam range 7.5 hingga 10.0 terdapat kemunculan data tertinggi yaitu diatas 200.




Rangkuman Grafik :

Semakin tinggi tingkat kemiskinan ternyata tidak terlalu mempengaruhi nilai rata lama sekolah. artinya ada kemungkinan nilai korelasi antara variabel kemiskinan dengan variabel rata lama sekolah tidak terlalu kuat.

3.5 Distribusi Data

Berdasarkan hasil pengolahan data akhir setelah melalui tahapan preprocessing, termasuk imputasi missing value dengan nilai median dan filtrasi data ekstrem menggunakan metode Interquartile Range, diperoleh parameter distribusi baru untuk variabel tingkat kemiskinan. Ruang sampel data kini dibatasi secara tegas oleh pagar pengaman dengan batas minimum sebesar 2,01% dan batas maksimum sebesar 25,00%. Dari dataset yang telah steril ini, didapatkan nilai rata-rata sebesar 13,64% dengan standar deviasi sebesar 6.61%. Nilai standar deviasi yang relatif terkendali ini menunjukkan jarak sebaran data yang stabil di sekitar nilai pusatnya, yang menjadi fondasi penting dalam pembentukan kurva distribusi peluang kontinu.




Analisis visual terhadap Fungsi Kepadatan Probabilitas menunjukkan adanya dinamika unik antara Kurva Densitas Empiris atau data riil lapangan bertanda garis merah dengan Kurva Normal Teoritis Gauss yang bertanda garis biru putus-putus. Model teoretis Distribusi Normal memprediksi bahwa massa peluang terbesar akan memuncak tajam secara simetris di sekitar nilai rata-rata 13,64%. Namun, data riil di lapangan menunjukkan karakteristik yang berbeda, di mana puncak kurva cenderung landai dan membentuk dataran bergelombang yang merata pada rentang tingkat kemiskinan 5% hingga 22%. Pada area ini, indeks kerapatan data atau density stabil berada di sekitar angka 0,04. Hal ini mengandung makna probabilitas bahwa setiap terjadi kenaikan rentang sebesar 1% pada angka kemiskinan, jumlah wilayah yang menempatinnya selalu konsisten menyumbang proporsi sekitar 4% dari total keseluruhan wilayah sampel. Fenomena homogenitas ini menyebabkan kedua kurva saling memotong silang; kurva teoretis menilai terlalu tinggi peluang di titik tengah, namun menilai terlalu rendah (underestimate) potensi kemunculan wilayah pada klaster kemiskinan rendah sekitar 5% dan klaster kemiskinan tinggi sekitar 20%.

Untuk memvalidasi asumsi normalitas secara lebih spesifik, dilakukan pengujian visual melalui Quantile-Quantile Plot. Grafik ini mengadu antara posisi urutan data riil lapangan pada sumbu Y terhadap urutan data ekspektasi teori matematika pada sumbu X. Hasil plot memperlihatkan pola sebaran data yang mem-

bentuk kurva S. Pada bagian massa data utama di area pusat distribusi dengan rentang Z-score -1 hingga 1, seluruh kumpulan titik sampel berhimpit secara linear dan menindih garis referensi merah diagonal dengan sangat rapi. Hal ini menjadi bukti konkret bahwa karakteristik data pada kluster menengah sudah memenuhi asumsi Distribusi Normal secara valid.

Q-Q Plot Uji Normalitas Kemiskinan



Melalui grafik Q-Q Plot yang dieksekusi, sumbu plot memetakan sebaran kuartil data riil (Sample Quantiles) terhadap kuartil ideal teoretis (Theoretical Quantiles). Hasil visualisasi menunjukkan bahwa kumpulan titik koordinat data (lingkaran hitam) menyebar dengan merapat, konsisten, dan menempel langsung di sepanjang garis lurus diagonal berwarna merah (qqline). Walaupun dijumpai adanya sedikit kerenggangan minor pada ujung ekor distribusi (tails) yang mencerminkan sisa nilai batas atas maksimal 25.00%, secara keseluruhan pola visual ini sah memenuhi kriteria Distribusi Normal. Oleh karena itu, penerapan rumus peluang berbasis statistik parametrik pada data ini dapat dipertanggungjawabkan akurasi.

Adapun deviasi berupa kelengkungan mendatar yang membelot dari garis merah pada ujung kiri bawah dan ujung kanan atas kurva bukanlah sebuah cacat data, melainkan representasi visual dari efek pemotongan ekor distribusi. Pola mendatar ini terjadi karena data sampel asli pada sumbu Y dipaksa berhenti akibat menabrak tembok batas fisik hasil filter outlier, yaitu pada angka 2,01% di ujung bawah (area Z-score negatif

yang merepresentasikan wilayah-wilayah di bawah rata-rata atau lebih sejahtera) dan angka 25,00% di ujung atas (area Z-score positif yang merepresentasikan wilayah di atas rata-rata).

Secara keseluruhan, meskipun terdapat pemangkasan mekanis di kedua ujung ekor kurva demi menjaga akurasi pemodelan, sebaran data kemiskinan ini dinilai sangat sehat, memiliki pola yang konsisten, dan sangat akurat untuk digunakan dalam perhitungan prediksi peluang kontinu menggunakan fungsi parametrik seperti pnorm maupun qnorm

3.6 Korelasi

Dilakukan uji coba korelasi setiap variabel dengan variabel lainnya menggunakan fungsi `cor()`. fungsi `cor()` adalah sebuah fungsi bawaan dari R untuk menghitung korelasi variabel.

```
data %>%
  select(tahun, kemiskinan, pengangguran, harapan_hidup, ipm, rata_lama_sekolah,
         pdrb_perkapita, akses_internet, jalan_baik, air_bersih) %>%
  cor()
```

##		tahun	kemiskinan	pengangguran	harapan_hidup
## tahun		1.000000000	0.023762438	0.0089601351	-0.0089076318
## kemiskinan		0.023762438	1.000000000	-0.0040915712	-0.0101805809
## pengangguran		0.008960135	-0.004091571	1.000000000	-0.0005811769
## harapan_hidup		-0.008907632	-0.010180581	-0.0005811769	1.000000000
## ipm		0.012433671	0.017107603	-0.0095668685	0.0107503625
## rata_lama_sekolah		0.007570889	0.002726949	-0.0035129347	-0.0077955254
## pdrb_perkapita		0.021804150	-0.003377190	-0.0131074829	0.0116531988
## akses_internet		0.007347926	-0.030219571	0.0176628784	0.0072260672
## jalan_baik		-0.015972733	0.022500168	0.0018004130	0.0069058248
## air_bersih		0.003951291	-0.002748371	0.0097386660	-0.0197316851
##		ipm	rata_lama_sekolah	pdrb_perkapita	akses_internet
## tahun		0.0124336707	0.0075708889	0.0218041497	0.0073479255
## kemiskinan		0.0171076028	0.0027269494	-0.0033771898	-0.0302195710
## pengangguran		-0.0095668685	-0.0035129347	-0.0131074829	0.0176628784
## harapan_hidup		0.0107503625	-0.0077955254	0.0116531988	0.0072260672
## ipm		1.000000000	0.0183760016	0.0253900142	-0.0002783895
## rata_lama_sekolah		0.0183760016	1.000000000	0.0009541835	-0.0034033723
## pdrb_perkapita		0.0253900142	0.0009541835	1.000000000	0.0022716753
## akses_internet		-0.0002783895	-0.0034033723	0.0022716753	1.000000000
## jalan_baik		0.0255016384	0.0497545292	0.0442979049	-0.0024272733
## air_bersih		0.0247423778	0.0129514671	-0.0149028213	-0.0074690979
##		jalan_baik	air_bersih		
## tahun		-0.015972733	0.003951291		
## kemiskinan		0.022500168	-0.002748371		
## pengangguran		0.001800413	0.009738666		
## harapan_hidup		0.006905825	-0.019731685		
## ipm		0.025501638	0.024742378		
## rata_lama_sekolah		0.049754529	0.012951467		
## pdrb_perkapita		0.044297905	-0.014902821		
## akses_internet		-0.002427273	-0.007469098		
## jalan_baik		1.000000000	0.023438515		
## air_bersih		0.023438515	1.000000000		

Agar bisa membahas korelasi variabel lebih lanjut. Dilakukan uji coba kepada dua variabel terpilih yaitu

kemiskinan dan **rata_lama_sekolah** menggunakan fungsi **cor.test()**. fungsi **cor.test()** adalah sebuah fungsi seperti **cor()** tetapi yang membedakan adalah fungsi **cor.test()** memberikan informasi lebih detail.

```
cor.test(data$kemiskinan, data$rata_lama_sekolah, method = "pearson")
```

```
##
## Pearson's product-moment correlation
##
## data: data$kemiskinan and data$rata_lama_sekolah
## t = 0.13588, df = 2483, p-value = 0.8919
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.03659785 0.04204332
## sample estimates:
## cor
## 0.002726949
```

Penjelasan lebih lanjut mengenai korelasi antara variabel kemiskinan dan rata lama sekolah akan dibahas lebih lanjut dibagian interpretasi.

3.7 Interpretasi

$H_0 = 0$ (Nilai korelasi antara kemiskinan dan rata lama sekolah tidak bernilai signifikan dari 0)

$H_1 \neq 0$ (Nilai korelasi antara kemiskinan dan rata lama sekolah bernilai signifikan dari 0)

Hasil analisis :

Nilai p-value lebih dari nilai yang ditentukan yaitu 0.05 (5%) sehingga bisa dinyatakan bahwa kita gagal menolak pernyataan H_0 . tidak terdapat cukup bukti untuk menyatakan adanya pengaruh signifikan antara variabel **kemiskinan** dengan **rata lama sekolah**.

BAB IV KESIMPULAN

4.1 Kesimpulan Utama

Berdasarkan seluruh rangkaian analisis statistik yang telah dilakukan terhadap dataset pembangunan wilayah menggunakan bahasa pemrograman R, diperoleh bahwa dataset mengandung *missing value* dan *outlier* yang perlu ditangani sebelum analisis lebih lanjut dilakukan. *Missing value* ditangani menggunakan metode *median imputation* karena sifatnya yang tidak mudah terpengaruh oleh nilai ekstrem, sedangkan *outlier* dieliminasi melalui metode *trimming* berbasis *Interquartile Range* (IQR). Proses pembersihan data ini terbukti efektif, ditandai dengan penurunan nilai maksimum tingkat kemiskinan secara signifikan dari 67,53% menjadi 25,00%.

Hasil statistika deskriptif dan visualisasi data menunjukkan adanya variasi kondisi pembangunan yang cukup mencolok antarwilayah, terutama pada indikator ekonomi (PDRB per kapita) dan kesejahteraan (tingkat kemiskinan). Pengujian distribusi probabilitas pada variabel kemiskinan membuktikan bahwa setelah pembersihan data, sebaran tingkat kemiskinan mendekati distribusi normal, yang dikonfirmasi melalui grafik histogram densitas dan Q-Q Plot. Probabilitas empiris wilayah dengan tingkat kemiskinan di bawah 10%

adalah sebesar 33,79%, sedangkan probabilitas teoretis berbasis distribusi normal Gaussian menghasilkan nilai yang berdekatan, yakni 29,10%.

Hasil uji korelasi Pearson menggunakan fungsi `cor.test()` menunjukkan bahwa nilai p-value melebihi ambang batas signifikansi $= 0,05$, sehingga H_0 gagal ditolak. Hal ini berarti tidak terdapat cukup bukti statistik untuk menyatakan adanya hubungan yang signifikan antara variabel kemiskinan dan rata-rata lama sekolah pada dataset ini.

4.2 Insight

Temuan analisis mengindikasikan bahwa pembangunan wilayah di Indonesia masih diwarnai oleh kesenjangan yang cukup nyata antara provinsi di Pulau Jawa dan wilayah luar Jawa. Selain itu, kehadiran *missing value* dan *outlier* dalam dataset mencerminkan kondisi pengumpulan data statistik di lapangan yang belum sepenuhnya sempurna, sehingga menegaskan bahwa tahapan data *pre-processing* merupakan langkah yang tidak dapat dilewati sebelum analisis lebih lanjut dilakukan.

Meskipun uji korelasi antara kemiskinan dan rata-rata lama sekolah tidak menghasilkan signifikansi statistik, arah hubungannya tetap selaras dengan teori. Ketiadaan signifikansi ini kemungkinan dipengaruhi oleh ukuran sampel yang terbatas serta adanya faktor-faktor lain yang turut berperan seperti akses internet, kondisi infrastruktur, dan kualitas layanan kesehatan yang juga memengaruhi tingkat kemiskinan secara bersamaan. Hal ini memperkuat pemahaman bahwa kemiskinan merupakan fenomena yang dipengaruhi oleh banyak faktor sehingga tidak dapat dijelaskan hanya oleh satu indikator pembangunan.

4.3 Saran

Pemerintah daerah dan pemangku kebijakan disarankan untuk memprioritaskan investasi di sektor pendidikan, khususnya peningkatan rata-rata lama sekolah di wilayah yang masih berada di bawah rata-rata nasional. Secara bersamaan, pemerataan infrastruktur dasar, akses internet, dan layanan kesehatan di wilayah tertinggal perlu terus didorong sebagai upaya pendukung dalam mengurangi tingkat kemiskinan, mengingat pembangunan wilayah merupakan persoalan yang memerlukan kebijakan terpadu dari berbagai sektor.

Untuk keperluan analisis lanjutan, uji regresi berganda (*multiple linear regression*) yang melibatkan seluruh variabel independen secara sekaligus sangat direkomendasikan guna memperoleh gambaran yang lebih lengkap mengenai faktor-faktor yang memengaruhi kemiskinan.

LAMPIRAN

```
library(dplyr)
library(ggplot2)

# memahami dataset
data <- read.csv("dataset/pembangunan_wilayah_missing_outlier.csv")
str(data)
head(data)
dim(data)

summary(data)
```

```

sapply(data, class)

options(scipen = 999)

numerik <- data[sapply(data, is.numeric)]

statistik_deskriptif <- data.frame(
  Variabel = names(select(data, where(is.numeric))),
  Mean = sapply(select(data, where(is.numeric)), mean, na.rm = TRUE),
  Median = sapply(select(data, where(is.numeric)), median, na.rm = TRUE),
  Min = sapply(select(data, where(is.numeric)), min, na.rm = TRUE),
  Q1 = sapply(select(data, where(is.numeric)), quantile, probs = 0.25, na.rm = TRUE),
  Q2 = sapply(select(data, where(is.numeric)), quantile, probs = 0.50, na.rm = TRUE),
  Q3 = sapply(select(data, where(is.numeric)), quantile, probs = 0.75, na.rm = TRUE),
  Max = sapply(select(data, where(is.numeric)), max, na.rm = TRUE),
  SD = sapply(select(data, where(is.numeric)), sd, na.rm = TRUE),
  Varians = sapply(select(data, where(is.numeric)), var, na.rm = TRUE)
)

statistik_deskriptif

# Missing value (median imputation) (1.3.3)
missing_value <- colSums(is.na(data))
missing_value

data <- data %>%
  mutate(across(where(is.numeric),
    ~ ifelse(is.na(.), median(., na.rm = TRUE), .)))

colSums(is.na(data))

# Outlier (1.3.4)
boxplot(data$pdrrb_perkapita,
  main = "Boxplot PDRB per Kapita",
  ylab = "Nilai",
  col = "Red")

boxplot(data$kemiskinan,
  main = "Boxplot Kemiskinan",
  ylab = "Nilai",
  col = "Red")

boxplot(data$pengangguran,
  main = "Boxplot Pengangguran",
  ylab = "Nilai",
  col = "Red")

boxplot(data$ipm,
  main = "Boxplot IPM",
  ylab = "Nilai",
  col = "Red")

boxplot(data$harapan_hidup,

```

```

    main = "Boxplot Harapan Hidup",
    ylab = "Nilai",
    col = "Red")

boxplot(data$rata_lama_sekolah,
        main = "Boxplot Rata-rata Lama Sekolah",
        ylab = "Nilai",
        col = "Red")

boxplot(data$akses_internet,
        main = "Boxplot Akses Internet",
        ylab = "Nilai",
        col = "Red")

boxplot(data$jalan_baik,
        main = "Boxplot Jalan Baik",
        ylab = "Nilai",
        col = "Red")

boxplot(data$air_bersih,
        main = "Boxplot Air Bersih",
        ylab = "Nilai",
        col = "Red")

iqr_pdrb <- IQR(data$pdrb_perkapita)
batas_bawah <- quantile(data$pdrb_perkapita, 0.25) - (1.5 * iqr_pdrb)
batas_atas <- quantile(data$pdrb_perkapita, 0.75) + (1.5 * iqr_pdrb)
data <- data %>%
  filter(pdrb_perkapita >= batas_bawah & pdrb_perkapita <= batas_atas)

iqr_kemiskinan <- IQR(data$kemiskinan)
batas_bawah <- quantile(data$kemiskinan, 0.25) - (1.5 * iqr_kemiskinan)
batas_atas <- quantile(data$kemiskinan, 0.75) + (1.5 * iqr_kemiskinan)
data <- data %>%
  filter(kemiskinan >= batas_bawah & kemiskinan <= batas_atas)

iqr_datapengangguran <- IQR(data$pengangguran)
batas_bawah <- quantile(data$pengangguran, 0.25) - (1.5 * iqr_datapengangguran)
batas_atas <- quantile(data$pengangguran, 0.75) + (1.5 * iqr_datapengangguran)
data <- data %>%
  filter(pengangguran >= batas_bawah & pengangguran <= batas_atas)

# Visualisasi data (1.3.5)

# 1. Visualisasi Barchart
daftarTahun <- levels(factor(data$tahun))
dataLaporan2020 <- data[data$tahun == 2020,]
dataLaporan2021 <- data[data$tahun == 2021,]
dataLaporan2022 <- data[data$tahun == 2022,]
dataLaporan2023 <- data[data$tahun == 2023,]
dataLaporan2024 <- data[data$tahun == 2024,]

data_visualisasi1 <- data.frame(

```

```

tahun = daftarTahun,
datalaporan1 = c(nrow(dataLaporan2020),
                  nrow(dataLaporan2021),
                  nrow(dataLaporan2022),
                  nrow(dataLaporan2023),
                  nrow(dataLaporan2024)
                )
)

data_visualisasi1

ggplot(data_visualisasi1, aes(x=tahun, y=datalaporan1)) +
  geom_col()+
  labs(x="Tahun",
       y="Laporan",
       title = "Jumlah Laporan dari tahun 2020 sampai 2024"
  )

# 2. Visualisasi Histogram
data %>%
  select(rata_lama_sekolah) %>%
  ggplot(aes(x = rata_lama_sekolah))+
  geom_histogram(
    bins = 15,
    fill = "#4E79A7",
    color = "white",
    linewidth = 0.5
  )+
  labs(x="Rata Lama Sekolah",
       y="Frekuensi",
       title = "Distribusi rata lama sekolah")

# 3. Visualisasi Scatter Plot
data %>%
  select(kemiskinan, pdrb_perkapita) %>%
  ggplot(aes(kemiskinan, log10(pdrb_perkapita)))+
  geom_point()+
  labs(x="kemiskinan",
       y="pdrb_perkapita",
       title = "Pengaruh kemiskinan terhadap pdrb_perkapita")+
  geom_smooth(method = "lm", se=FALSE)

# 4. Visualisasi Scatter Plot
data %>%
  select(kemiskinan, rata_lama_sekolah) %>%
  ggplot(aes(kemiskinan, rata_lama_sekolah))+
  geom_point()+
  labs(x="kemiskinan",
       y="rata lama sekolah",

```

```

    title = "Pengaruh kemiskinan terhadap rata lama sekolah")+
    geom_smooth(method = "lm", se=FALSE)

# 5. Visualisai Barchart
daftarProvinsi <- levels(factor(data$provinsi))
dataLaporanBanten <- data[data$provinsi == "Banten",]
dataLaporanJawaTimur <- data[data$provinsi == "Jawa Timur",]
dataLaporanJakarta <- data[data$provinsi == "DKI Jakarta",]
dataLaporanJawaBarat <- data[data$provinsi == "Jawa Barat",]
dataLaporanJawaTengah <- data[data$provinsi == "Jawa Tengah",]
dataLaporanKalimantanTimur <- data[data$provinsi == "Kalimantan Timur",]
dataLaporanPapua <- data[data$provinsi == "Papua",]
dataLaporanSulawesiSelatan <- data[data$provinsi == "Sulawesi Selatan",]
dataLaporanSumateraBarat <- data[data$provinsi == "Sumatera Barat",]
dataLaporanSumateraUtara <- data[data$provinsi == "Sumatera Utara",]

View(dataLaporanJawaBarat)
data_visualisasi5 <- data.frame(
  provinsi = daftarProvinsi,
  datalaporan2 = c(nrow(dataLaporanBanten),
                   nrow(dataLaporanJakarta),
                   nrow(dataLaporanJawaBarat),
                   nrow(dataLaporanJawaTengah),
                   nrow(dataLaporanJawaTimur),
                   nrow(dataLaporanKalimantanTimur),
                   nrow(dataLaporanPapua),
                   nrow(dataLaporanSulawesiSelatan),
                   nrow(dataLaporanSumateraBarat),
                   nrow(dataLaporanSumateraUtara)
  )
)

ggplot(data_visualisasi5, aes(x=provinsi, y=datalaporan2)) +
  geom_col()+
  labs(x="Tahun",
       y="Laporan",
       title = "Jumlah Laporan dari berbagai provinsi dari tahun 2020 sampai 2024"
  )

# Analisis Korelasi (1.3.7)

data %>%
  select(tahun, kemiskinan, pengangguran, harapan_hidup, ipm, rata_lama_sekolah,
         pdrb_perkapita, akses_internet, jalan_baik, air_bersih) %>%
  cor()

cor.test(data$kemiskinan, data$rata_lama_sekolah, method = "pearson")

```

```

# Analisis Probabilitas dan Distribusi Data

data <- read.csv("dataset/pembangunan_wilayah_missing_outlier.csv")

hasil_awal <- data.frame(
  Variabel = "kemiskinan",
  Mean      = mean(data$kemiskinan, na.rm = TRUE),
  Median    = median(data$kemiskinan, na.rm = TRUE),
  Min       = min(data$kemiskinan, na.rm = TRUE),
  Q1        = as.numeric(quantile(data$kemiskinan, 0.25, na.rm = TRUE)),
  Q3        = as.numeric(quantile(data$kemiskinan, 0.75, na.rm = TRUE)),
  Max       = max(data$kemiskinan, na.rm = TRUE),
  SD        = sd(data$kemiskinan, na.rm = TRUE),
  Varians   = var(data$kemiskinan, na.rm = TRUE)
)

print("=== STATISTIK DESKRIPTIF AWAL ===")
print(hasil_awal)

# Imputasi nilai NA khusus pada variabel kemiskinan menggunakan nilai tengah
data <- data %>%
  mutate(kemiskinan = ifelse(is.na(kemiskinan), median(kemiskinan, na.rm = TRUE), kemiskinan))

# Menghitung batas pencilan untuk variabel kemiskinan
iqr_kemiskinan <- IQR(data$kemiskinan)
batas_bawah    <- quantile(data$kemiskinan, 0.25) - (1.5 * iqr_kemiskinan)
batas_atas     <- quantile(data$kemiskinan, 0.75) + (1.5 * iqr_kemiskinan)

# Menyaring data untuk mendapatkan dataset yang bersih
data_bersih <- data %>%
  filter(kemiskinan >= batas_bawah & kemiskinan <= batas_atas)

mean_kemiskinan <- mean(data_bersih$kemiskinan)
sd_kemiskinan   <- sd(data_bersih$kemiskinan)

hasil_akhir <- data.frame(
  Variabel = "kemiskinan",
  Mean_Mu  = mean_kemiskinan,
  Median   = median(data_bersih$kemiskinan),
  SD_Sigma = sd_kemiskinan,
  Min      = min(data_bersih$kemiskinan),
  Max      = max(data_bersih$kemiskinan)
)

print("=== PARAMETER DISTRIBUSI DATA AKHIR ===")
print(hasil_akhir)

# A. Histogram & Grafik Fungsi Kepadatan Probabilitas (PDF)
hist(data_bersih$kemiskinan, probability = TRUE,

```

```

main = "Perbandingan Distribusi Peluang Kemiskinan",
xlab = "Tingkat Kemiskinan (%)", col = "lightblue", border = "white",
ylim = c(0, max(density(data_bersih$kemiskinan)$y) * 1.2))

# Kurva Densitas Empiris (Garis Merah berdasarkan data riil)
lines(density(data_bersih$kemiskinan), col = "red", lwd = 2)

# Kurva Distribusi Normal Teoritis Gauss (Garis Biru Putus-putus)
x_axis <- seq(min(data_bersih$kemiskinan), max(data_bersih$kemiskinan), length = 100)
y_axis <- dnorm(x_axis, mean = mean_kemiskinan, sd = sd_kemiskinan)
lines(x_axis, y_axis, col = "blue", lwd = 2, lty = 2)

legend("topright", legend = c("Empiris (Data Riil)", "Teoritis (Normal Gauss)"),
      col = c("red", "blue"), lty = c(1, 2), lwd = 2)

# B. Q-Q Plot untuk Uji Validitas Distribusi Normal
qqnorm(data_bersih$kemiskinan, main = "Q-Q Plot Uji Normalitas Kemiskinan")
qqline(data_bersih$kemiskinan, col = "red", lwd = 2)

# Kasus Skenario: Berapa peluang suatu wilayah memiliki tingkat kemiskinan di bawah 10%?
batas_kasus <- 10

# A. Probabilitas Empiris (Berdasarkan frekuensi relatif data lapangan)
prob_empiris <- mean(data_bersih$kemiskinan < batas_kasus)

# B. Probabilitas Teoritis (Berdasarkan luasan kurva Distribusi Normal / CDF)
prob_teoritis <- pnorm(batas_kasus, mean = mean_kemiskinan, sd = sd_kemiskinan)

# C. Inverse CDF (Mencari nilai kritis untuk ambang batas peluang 15% terendah)
nilai_kritis_15 <- qnorm(0.15, mean = mean_kemiskinan, sd = sd_kemiskinan)

cat("\n=====\\n")
cat("=== ANALISIS ELEMEN PROBABILITAS KEMISKINAN ===\\n")
cat("=====\\n")
cat("1. Peluang Empiris  $P(X < 10\%)$  :", prob_empiris, "\\n")
cat("2. Peluang Teoritis  $P(X < 10\%)$  :", prob_teoritis, "\\n")
cat("3. Batas nilai kemiskinan untuk peluang kumulatif 15% terendah:", nilai_kritis_15, "\\n")
cat("=====\\n")

```

DAFTAR PUSTAKA

-
- Alam S, Ayub MS, Arora S, Khan MA. 2023. An investigation of the imputation techniques for missing values in ordinal data enhancing clustering and classification analysis validity. *Decision Analytics Journal*. 9:100341. doi:10.1016/j.dajour.2023.100341.
- Kaiser J. 2014. Dealing with Missing Values in Data. *Journal of System Integration*. 5(1).
- Kuncoro, M. 2010. *Ekonomi Pembangunan: Teori, Masalah, dan Kebijakan* (Edisi ke-5). UPP STIM YKPN.

- Kwak SK, Kim JH. 2017. Statistical data preparation: management of missing values and outliers. Korean Journal of Anesthesiol. 70(4):407. doi:10.4097/kjae.2017.70.4.407.
- Mankiw, N. G. 2018. Makroekonomi (Edisi ke-9). Penerbit Erlangga.
- Sukirno, S. 2011. Makroekonomi Teori Pengantar (Edisi ke-3). PT Raja Grafindo Persada.
- Todaro, M. P., & Smith, S. C. 2015. Pembangunan Ekonomi (Edisi ke-11). Penerbit Erlangga.
- Purnama YC. 2026. kenapa p-value Harus Dibawah 0.05?. 12(52):1-3.